

Ordenação de Dados

Algoritmos eficientes

Algoritmo	Melhor caso	Pior caso	Caso médio
Inserção	$O(n)$	$O(n^2)$	$O(n^2)$
Seleção	$O(n^2)$	$O(n^2)$	$O(n^2)$
Bolha	$O(n)$	$O(n^2)$	$O(n^2)$
Bogosort	$O(n)$	$O(\infty)$	$O(n \cdot n!)$

Algoritmos eficientes:

Caso médio

$O(n \log n)$

Algoritmos eficientes

- **Quick sort**
- **Heap sort**
- **Merge sort**

Quicksort/ Quick Sort (1961)

- Método dividir para conquistar
- Algoritmo
 - 1) escolher um valor (**pivô**) do conjunto a ordenar
 - 2) particionar o conjunto em dois subconjuntos: menores e maiores que o pivô
 - 3) repetir recursivamente para cada subconjunto (subconjuntos de tamanho zero ou um estão ordenados e não são mais repassados)

Quicksort: algoritmo de Lomuto

algorithm quicksort(A, lo, hi) **is**

if lo < hi **then**

 p := partition(A, lo, hi)

 quicksort(A, lo, p - 1)

 quicksort(A, p + 1, hi)

algorithm partition(A, lo, hi) **is**

 pivot := A[hi]

 i := lo

for j := lo **to** hi **do**

if A[j] < pivot **then**

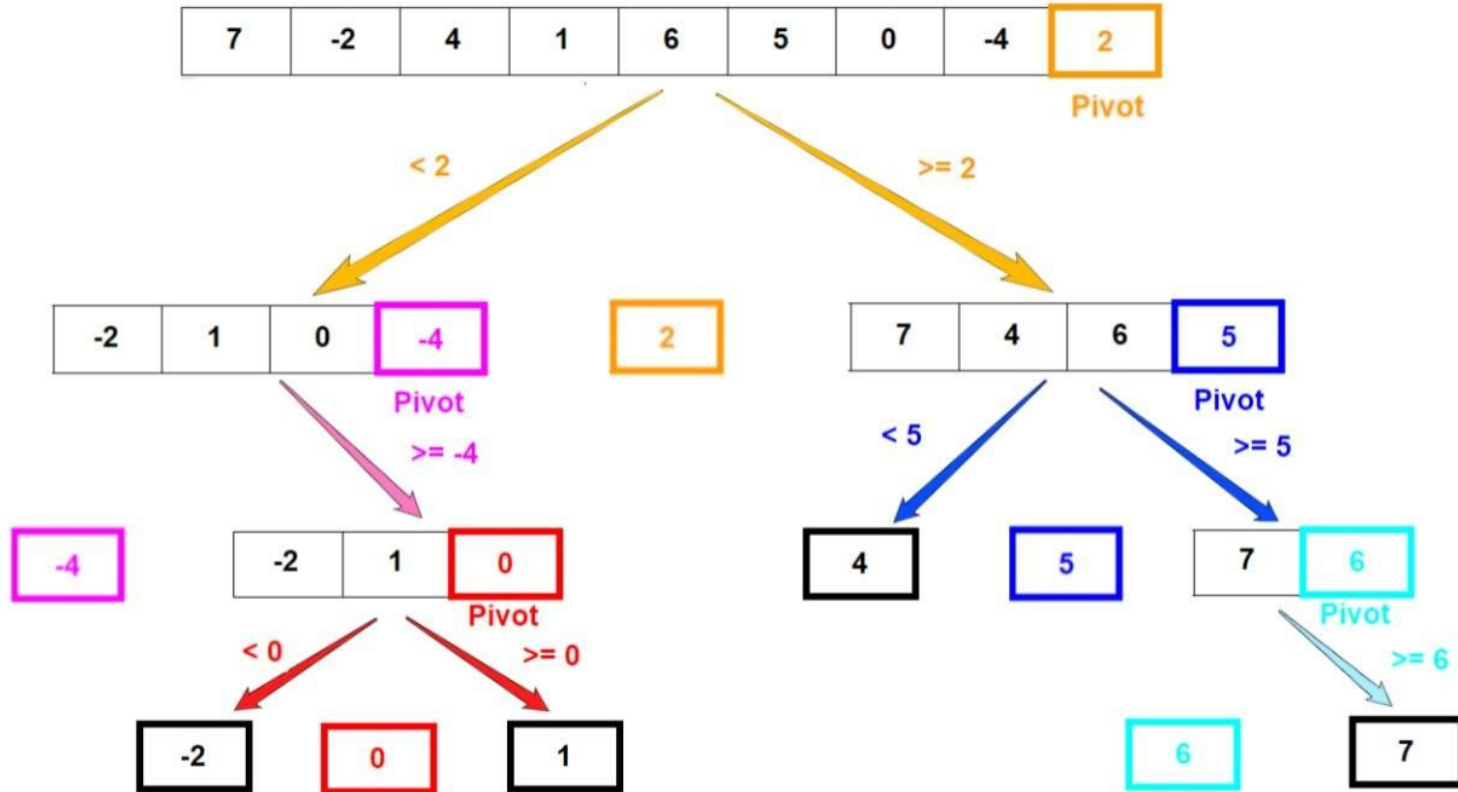
 swap A[i] with A[j]

 i := i + 1

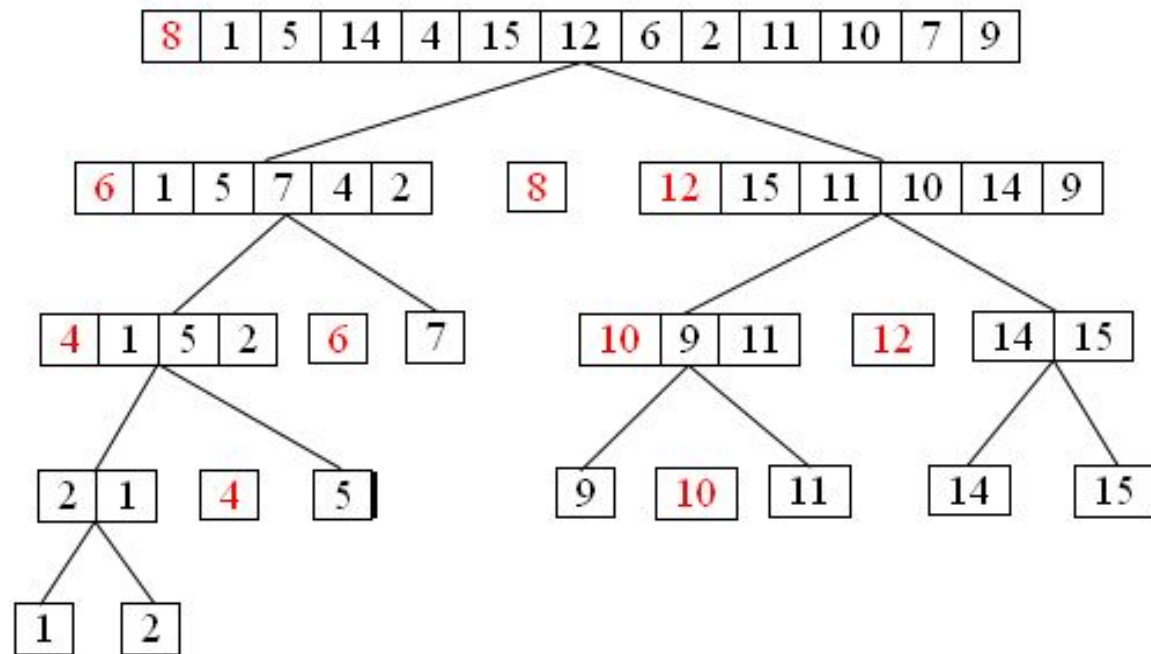
 swap A[i] with A[hi]

return i

Quicksort




Quicksort



Ao final, junta-se os elementos

1 2 4 5 6 7 8 9 10 11 12 14 15

Quicksort: degeneração



Quicksort: problema

- Escolha do pivô
 - Pivô ótimo == mediana $\rightarrow O(n \log n)$
 - Pivô ruim == degeneração $\rightarrow O(n^2)$

Quicksort


- Veloz e simples de implementar
- Tende a dar melhor resultado que outros algoritmos $O(n \log n)$
- Pode degenerar, mas há formas de evitar este problema
- Não usa estruturas auxiliares explícitas, pois as implementações são recursivas (usam espaço de pilha de execução)

Heapsort / Heap Sort (1964)


- Baseado no uso da estrutura de Heap
- Algoritmo
 - 1) construir heap (buildMaxHeap() ou heapify())
 - 2) retirar raiz inserindo último elemento em seu lugar. Colocar elemento retirado na posição final do conjunto ordenado.
 - 3) chamar siftDown() para a nova raiz
 - 4) enquanto houver elementos no heap, voltar para o passo 2

Heapsort: buildMaxHeap()

{45, 36, 54, 27, 63, 72, 61, 18}



Heapsort. Criação

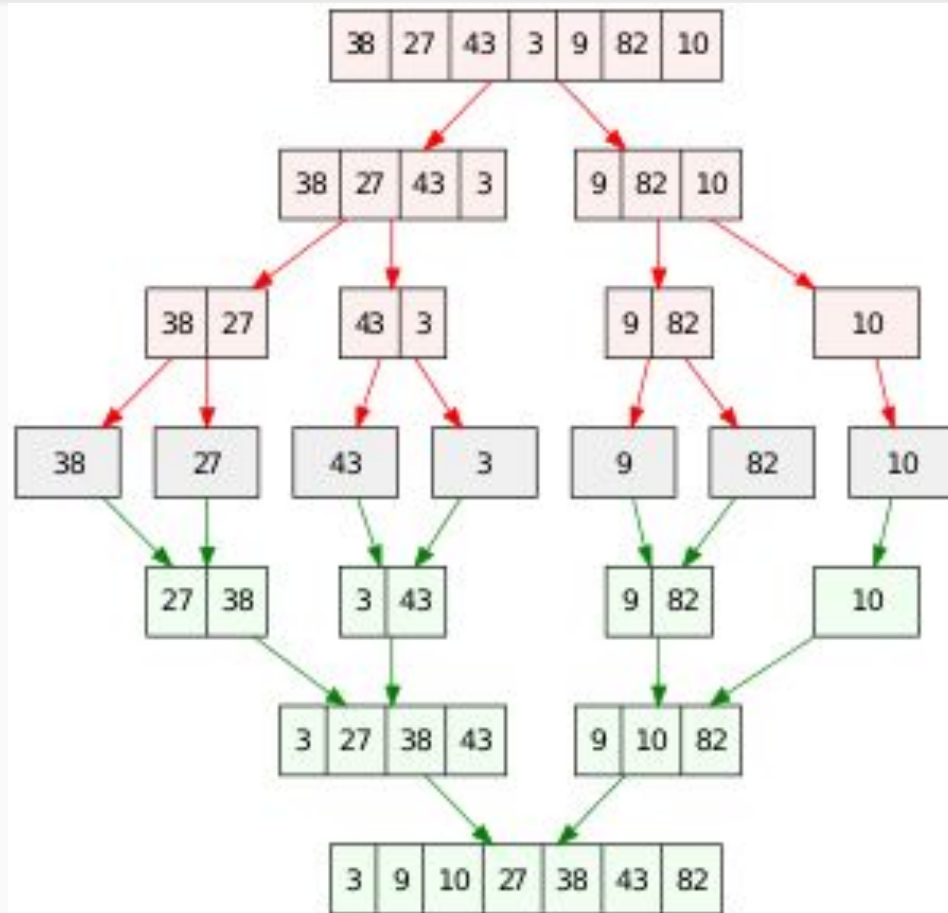


Heapsort

- Não degenera
- Limite superior de execução $\rightarrow O(n \log n)$
 - Adequado a sistemas de tempo-real e sistemas de segurança crítica (quicksort pode sofrer ataque que força degeneração)
- Em geral um pouco mais lento que melhores implementações do Quicksort
- Exige construção do Heap (estrutura extra)

Mergesort / Merge Sort

- Método divisão-e-conquista baseado em *merge*
- Algoritmo:
 - 1) Dividir o conjunto em n subconjuntos de tamanho 1
 - 2) Repetidamente realizar *merge* dos subconjuntos até haver apenas 1



Mergesort

- Estável
- Usa memória extra (nas implementações mais comuns)
- Adequado à paralelização
- Adequado à uso externo

Algoritmos eficientes

Algoritmo	Melhor caso	Pior caso	Caso médio
Bogosort	$O(n)$	$O(\infty)$	$O(n*n!)$
Inserção	$O(n)$	$O(n^2)$	$O(n^2)$
Seleção	$O(n^2)$	$O(n^2)$	$O(n^2)$
Bolha	$O(n)$	$O(n^2)$	$O(n^2)$
Quicksort	$O(n \log n)$	$O(n^2)$	$O(n \log n)$
Heapsort	$O(n \log n)$	$O(n \log n)$	$O(n \log n)$
Mergesort	$O(n \log n)$	$O(n \log n)$	$O(n \log n)$

Outros algoritmos

- Cocktail Shaker
- Shell Sort
- Bucketsort
- Counting Sort
- LSD Radix
- MSD Radix
- outros...

Cocktail Shaker / Bolha bidirecional

- Variação do Bubble, com passadas bidirecionais
- Marginalmente melhor que o Bubble
 - Próximo a $O(n)$ para listas quase ordenadas

Shell Sort / Shellsort

Gaps = $\{N/2, N/4, \dots, 2, 1\}$

Para cada gap em Gaps

Realizar insertion sort na lista gerada pelos elementos separados por gap

Shell Sort / Shellsort

Listas de gaps conhecidas:

Knuth Gaps (1973) = {1, 4, 13, 40, 121, 364, 1093, 3280, 9841}

Ciura Gaps (2001) = {1, 4, 10, 23, 57, 132, 301, 701, 1750}

Tokuda Gaps (2021) = {1, 4, 9, 20, 45, 102, 230, 516, 1158}

...



Bucket Sort

Inicializar um vetor de “baldes” vazios

Vá para o vetor original, colocando cada elemento em um balde

Ordenar cada balde não-vazio

Colocar os elementos dos baldes não-vazios no vetor original



Bucket Sort

Que algoritmo usar para ordenar um balde?

O que acontece se distribuição não for uniforme? (ou pior, se todos os dados forem para o mesmo balde?)

Uso de estruturas dinâmicas para criar os baldes em memória (listas, arrays dinâmicos, etc)

Counting Sort

- 1- encontrar maior valor dos dados (max)
- 2- inicializar vetor cont, de tamanho max+1, com zeros
- 3- para cada elemento dos dados, incrementar o valor de cont[elemento] (criar um histograma)
- 4- realizar uma soma acumulativa ou soma de prefixos no vetor cont
- 5- criar um vetor de saída, com tamanho igual ao dos dados
- 6- para cada elemento dos dados, colocar o mesmo na posição saída[cont[elemento]] e decrementar o valor de cont[elemento]. Percorrer os dados em ordem inversa para manter estabilidade.



Counting Sort

Não comparativo

Algoritmo de ordenação de inteiros “pequenos” e positivos

Diferença entre menor e maior valor dita a complexidade

$O(n+k)$ onde k é a faixa de valores não negativos de dados

Nos casos em que k (maior valor) for muito menor que n (número de dados), o algoritmo possui boa eficiência de espaço

Variante com uso de mapa de bits em caso de chaves únicas (ou para realizar unificação de chaves)

Radix Sort

Não comparativo

Dois subtipos: LSD (*Least Significant Digit*) e MSD (*Most Significant Digit*)

Radix Sort - LSD

Para cada dígito, a partir do menos significativo, nos dados de entrada, colocar o dado atual no *bucket* correspondente

Dados = [170, 45, 75, 90, 2, 802, 2, 66]

Primeira rodada:

Dados = [{170, 90}, {2, 802, 2}, {45, 75}, {66}]

Segunda rodada:

Dados = [{02, 802, 02}, {45}, {66}, {170, 75}, {90}]

Terceira rodada:

Dados = [{002, 002, 045, 066, 075, 090}, {170}, {802}]

Radix Sort - MSD

Para cada dígito, a partir do mais significativo, nos dados de entrada, colocar o dado atual no *bucket* correspondente

Repetir recursivamente, para cada *bucket* com mais de um dado, para o próximo dígito mais significativo

Dados = [170, 045, 075, 025, 002, 024, 802, 066]

Primeira rodada:

Dados = [{045}, {075}, {025}, {002}, {024}, {066}, {170}, {802}]

Segunda rodada:

Dados = [{ {002} }, { {025}, {024} }, {045}, {066}, {075} }, 170, 802]

Terceira rodada:

Dados = [002, { {024}, {025} }, 045, 066, 075 , 170, 802]

Ordenação de dados - algoritmos atuais

- Híbridos
 - Introsort
 - Timsort

Introsort / Introspective sort (1997)

- Desenvolvido para uso na biblioteca padrão do C++
- Presente nas bibliotecas padrão em Go, Java e .NET
- Combina quicksort, heapsort e inserção (ou Shellsort)
 - Começa com quicksort, alternando para heapsort se o nível de recursão ultrapassa um *threshold* baseado em $\log n$, alternando para inserção quando o número de elementos está abaixo de um limite (arbitrariamente escolhido)
- Busca os benefícios de cada algoritmo

Introsort / Introspective sort (1997)


- ordenar(dados)
 - $\text{maxDepth} = (\log_2 \text{length}(\text{dados})) * 2$
 - introsort(dados, maxDepth)
- introsort(dados, maxDepth)
 - $N = \text{length}(\text{dados})$
 - if $N < 16$
 - insertion(dados)
 - else if $\text{maxDepth} == 0$
 - heapsort(dados)
 - Else
 - $P = \text{partition}(\text{dados})$
 - introsort($A[1:p-1]$, maxdepth - 1)
 - introsort($A[p+1:N]$, maxdepth - 1)

Timsort (2002)

- Derivado de Merge sort e inserção
- Algoritmo padrão de ordenação para Python (desde versão 2.3)
 - Também usado em Java, Android, Swift, Rust
- Projetado para aproveitar *runs* (sequências ordenadas) que ocorrem naturalmente nos dados
- Reduz o número de comparações necessárias

Timsort (2002)

- Algoritmo:
 - a. Iterar sobre os dados coletando *runs* e colocando-as em uma pilha (se não há uma *run*, ou não alcança um tamanho mínimo, cria-se uma por inserção)
 - Toda vez que as *runs* no topo da pilha preenchem um critério, elas sofrem merge
 - Quando os dados na entrada terminam, as *runs* na pilha sofrem merge até haver somente um conjunto ordenado restante
- Para obter merges balanceados, considere-se as 3 *runs* no topo da pilha (X, Y e Z) e as regras abaixo:
 - a. $\text{length}(Z) > \text{length}(X + Y)$
 - b. $\text{length}(Y) > \text{length}(X)$
- Se alguma regra for violada, fazer merge de Y com o menor entre X e Z até rebalancear, para depois procurar a próxima *run*



Timsort (2002)

- Os critérios de merge servem para:
 - manter os merges (aproximadamente) balanceados, enquanto mantém um compromisso entre não haver merges com muita frequência, explorar a existência de *runs* na cache e manter a decisão sobre o merge simples
- Timsort original não é *in-place*. Implementações desta forma possuem overhead de espaço ($O(N)$).

Timsort (2002)

- Implementações *in-place* possuem overhead de tempo
 - Para minimizar isto, criou-se uma otimização que diminui tanto espaço quanto tempo:
 - Faz-se uma busca binária para encontrar onde o primeiro elemento da segunda *run* será inserido na primeira
 - Faz-se outra busca para encontrar a posição de inserção do último elemento da segunda *run* na primeira
 - Elementos antes da primeira inserção e depois da última não serão modificados, então são deslocados para suas posições finais
 - Faz-se o merge dos elementos restantes na primeira *run* com a segunda no espaço reservado entre as anteriores

Timsort (2002)

Outras otimizações incluem:

- Modo “galopante”
 - Se durante o merge forem encontrados muitos elementos consecutivos da mesma *run* na ordem correta, alterna-se para modo “galopante”, em que inicia-se uma busca exponencial pelo fim da sequência
- *Runs* descendentes
 - Se for encontrada uma sequência estritamente descendente, a mesma é revertida ao ser levada para a pilha
- Tamanho mínimo de *run*
 -